

Heston-Asian Opcióárazás: Elméleti bevezetés

Ábris

0. Világ megteremtése

Tegyük fel, hogy a pénzügyi piacokra teljesül az NFLVR. (No Free Lunch with Vanishing Risk) Ekkor Delbaen–Schachermayer tétel szerint létezik ekvivalens maringálmérték Q . Mivel két Wiener-folyamat hajtja a dinamikát, és csak egy kockázatos eszközünk van, ezért a piac nem teljes, azaz a pénzügyi matematika második alaptétele nem áll fenn rá, azaz nem egyértelmű az ekvivalens martingálmérték ($Q \sim P$)

1. A Kiinduló Sztochasztikus Differenciálegyenletek (SDE)

A levezetést a valós mérték (P) szerinti dinamikákból indítjuk. Az S_t a részvényárfolyam, v_t a variancia, A_t pedig az ázsiai opcióhoz szükséges Átlagár T-szerese.

Részvényárfolyam dinamikája

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_{1,t}$$

ahol μ a valós várható hozam.

Variancia dinamikája

$$dv_t = \kappa(\theta - v_t)dt + \sigma_v \sqrt{v_t} dW_{2,t}$$

Integrál dinamikája

Mivel $A_t = \int_0^t S_u du$, ennek differenciálja tisztán determinisztikus (nincs benne dW):

$$dA_t = S_t dt$$

Korrelációs szabály

A két Wiener-folyamat közötti kapcsolat:

$$dW_{1,t}dW_{2,t} = \rho dt$$

2. Mértékváltás

Ahhoz, hogy áttérjünk a fizikai P mértékről a kockázatsemleges Q mértékre, a többdimenziós Girsanov-tételt alkalmazzuk. Be kell vezetnünk két folyamatot, amelyek a kockázat piaci árait reprezentálják:

- $\lambda_1(t, S_t, v_t)$: az árfolyamkockázat piaci ára
- $\lambda_2(t, S_t, v_t)$: a volatilitáskockázat piaci ára

Definiáljuk az új, Q -mérték alatti standard Wiener-folyamatokat ($\widetilde{W}_1, \widetilde{W}_2$):

$$\begin{aligned} d\widetilde{W}_{1,t} &= dW_{1,t} + \lambda_1 dt & \implies & dW_{1,t} = d\widetilde{W}_{1,t} - \lambda_1 dt \\ d\widetilde{W}_{2,t} &= dW_{2,t} + \lambda_2 dt & \implies & dW_{2,t} = d\widetilde{W}_{2,t} - \lambda_2 dt \end{aligned}$$

2.1. Az árfolyamdinamika transzformációja

Helyettesítsük be $dW_{1,t}$ -et az eredeti árfolyamdinamikába:

$$\begin{aligned} dS_t &= \mu S_t dt + \sqrt{v_t} S_t (d\widetilde{W}_{1,t} - \lambda_1 dt) \\ dS_t &= (\mu - \lambda_1 \sqrt{v_t}) S_t dt + \sqrt{v_t} S_t d\widetilde{W}_{1,t} \end{aligned}$$

A kockázatsemleges árazás alapelve, hogy a diszkontált részvényárfolyamnak ($e^{-rt} S_t$) martingálnak kell lennie Q alatt, ami azt jelenti, hogy a driftnek pontosan rS_t -nek kell lennie. Ebből meghatározható λ_1 :

$$\mu - \lambda_1 \sqrt{v_t} = r \quad \implies \quad \lambda_1 = \frac{\mu - r}{\sqrt{v_t}}$$

Így a részvény dinamikája a Q mérték alatt:

$$dS_t = rS_t dt + \sqrt{v_t} S_t d\widetilde{W}_{1,t}$$

2.2. A varianciadinamika transzformációja

Hasonlóan behelyettesítve $dW_{2,t}$ -t a variancia egyenletébe:

$$\begin{aligned} dv_t &= \kappa(\theta - v_t)dt + \sigma_v\sqrt{v_t}(d\widetilde{W}_{2,t} - \lambda_2 dt) \\ dv_t &= [\kappa(\theta - v_t) - \lambda_2\sigma_v\sqrt{v_t}]dt + \sigma_v\sqrt{v_t}d\widetilde{W}_{2,t} \end{aligned}$$

Mivel a variancia nem kereskedhető termék, λ_2 értékét nem rögzíti egyértelműen az arbitrázsmentesség. Heston (1993) klasszikus feltételezése szerint a volatilitás kockázati prémiuma arányos a volatilitással:

$$\lambda_2(t, S_t, v_t) = \lambda\sqrt{v_t}$$

ahol λ egy konstans. Ezt beírva a drift kifejezésébe:

$$dv_t = [\kappa(\theta - v_t) - \lambda\sigma_v v_t]dt + \sigma_v\sqrt{v_t}d\widetilde{W}_{2,t}$$

Rendezzük át a driftet:

$$\kappa\theta - (\kappa + \lambda\sigma_v)v_t = \kappa^*(\theta^* - v_t)$$

Ahol a kockázatmentes paraméterek:

$$\kappa^* = \kappa + \lambda\sigma_v, \quad \theta^* = \frac{\kappa\theta}{\kappa + \lambda\sigma_v}$$

A teljes rendszer dinamikája tehát az egyértelműsített Q martingálmérték alatt:

$$\begin{aligned} dS_t &= rS_tdt + \sqrt{v_t}S_td\widetilde{W}_{1,t} \\ dv_t &= \kappa^*(\theta^* - v_t)dt + \sigma_v\sqrt{v_t}d\widetilde{W}_{2,t} \\ dA_t &= S_tdt \end{aligned}$$

Ez a transzformáció indokolja, hogy a 3. fejezetben felírt Itô-kifejezés determinisztikus részében (a PDE-ben) a variancia driftjeként miért a $\kappa^*(\theta^* - v_t)d$ tag jelenik meg,.

3. A Bizonyítandó Parciális Differenciálegyenlet

A cél, hogy az $U(t, S, v, A)$ opciós árfelületre felírjuk a többdimenziós Itô-lemmát, majd egy kockázatmentes (Delta- és Vega-fedezett) portfólió kialakításával és az arbitrázsmentesség feltételével ($d\Pi = r\Pi dt$) eljussunk az alábbi egyenlethez. (Valójában ekkor feltételezzük, hogy van valamilyen eszköz, amellyel le tudjuk fedezni a Vegát)

$$\begin{aligned} \frac{\partial U}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 U}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 U}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 U}{\partial v^2} \\ + rS\frac{\partial U}{\partial S} + \kappa^*(\theta^* - v_t)d\frac{\partial U}{\partial v} + S\frac{\partial U}{\partial A} - rU = 0 \end{aligned}$$

Tétel: Itô–formula: Ha F kétszer folyamatosan deriválható n -változós függvény, és $(X_k)_{k=1}^n$ folytonos szemimartingálók, akkor tetszőleges t időpont-ra:

$$F(X(t)) - F(X(0)) = \sum_{k=1}^n \int_0^t \frac{\partial F}{\partial x_k}(X(s)) dX_k(s) + \frac{1}{2} \sum_{i,j} \int_0^t \frac{\partial^2 F}{\partial x_i \partial x_j}(X(s)) d[X_i, X_j](s).$$

Látható, hogy a Jobboldalon az első tag egy sztochasztikus integrál, a $dX_k(s)$ miatt, a második, pedig egy sima Stieltjes, a kvadratikus variáció miatt.

Ez azt jelenti az Itô–formula szerint, hogy egy lokális martingál szerinti kétszer folytonosan differenciálható függvény egy sztochasztikus integrál (vagyis lokális martingál), és egy korlátos függvény összegeként áll elő, vagyis egy szemimartingál.

Használjuk az Ito-formula definícióját.

$$\begin{aligned} F(X(t)) - F(X(0)) &= \int_0^t \frac{\partial F}{\partial S} dS + \int_0^t \frac{\partial F}{\partial v} dv + \int_0^t \frac{\partial F}{\partial A} dA + \int_0^t \frac{\partial F}{\partial t} dt + \\ &+ \frac{1}{2} \int_0^t \frac{\partial^2 F}{\partial S^2} d[S, S] + \frac{1}{2} \int_0^t \frac{\partial^2 F}{\partial v^2} d[v, v] + \frac{1}{2} \int_0^t \frac{\partial^2 F}{\partial A^2} d[A, A] + \frac{1}{2} \int_0^t \frac{\partial^2 F}{\partial t^2} d[t, t] + \\ &+ \int_0^t \frac{\partial^2 F}{\partial S \partial A} d[S, A] + \int_0^t \frac{\partial^2 F}{\partial S \partial t} d[S, t] + \int_0^t \frac{\partial^2 F}{\partial S \partial v} d[S, v] + \int_0^t \frac{\partial^2 F}{\partial A \partial t} d[A, t] + \\ &+ \int_0^t \frac{\partial^2 F}{\partial A \partial v} d[v, A] + \int_0^t \frac{\partial^2 F}{\partial t \partial v} d[t, v] \end{aligned}$$

Triviális, hogy azok a kvadratikus variációs tagok, amelyekben t van 0-t adnak, így azok kiesnek, valamint $dA = Sdt$ miatt ugyanez igaz az A -s tagokra is.

Most nézzük meg a maradék kvadratikus variációs tagokat, 3 tagot kell megvizsgálnunk.:

$$\int_0^t \frac{\partial^2 F}{\partial S^2} d[S, S] = \int_0^t \frac{\partial^2 F}{\partial S^2} [\mu S_t dt + \sqrt{v_t} S_t dW_{1,t}] \stackrel{[W,t],[t,t]=0}{=} \int_0^t \frac{\partial^2 F}{\partial S^2} v_t S_t^2 dt$$

A fentebbi indokálás miatt ugyanúgy:

$$\int_0^t \frac{\partial^2 F}{\partial v^2} d[v, v] \stackrel{[W,t],[t,t]=0}{=} \int_0^t \frac{\partial^2 F}{\partial v^2} \sigma_v^2 v_t dt$$

Most nézzük meg $[v, S]$ -t:

$$\begin{aligned} d[S, v] &= (\mu S_t dt + \sqrt{v_t} S_t dW_{1,t}) (\kappa(\theta - v_t) dt + \sigma_v \sqrt{v_t} dW_{2,t}) \stackrel{[W,t],[t,t]=0}{=} \sqrt{v_t} S_t dW_{1,t} \sigma_v \sqrt{v_t} dW_{2,t} \\ &= S_t \sigma_v v_t \rho dt \end{aligned}$$

Azaz:

$$\int_0^t \frac{\partial^2 F}{\partial S \partial v} d[S, v] = \int_0^t \frac{\partial^2 F}{\partial S \partial v} S_t \sigma_v v_t \rho dt$$

. Behelyettesítve az SDE-ket:

$$\begin{aligned} dF &= \frac{\partial F}{\partial S} (r S dt + \sqrt{v} S dW_1) + \frac{\partial F}{\partial v} (\kappa(\theta - v) dt + \sigma_v \sqrt{v} dW_2) + \frac{\partial F}{\partial A} (S dt) + \frac{\partial F}{\partial t} dt + \\ &\quad + \frac{1}{2} \frac{\partial^2 F}{\partial S^2} (v S^2 dt) + \frac{1}{2} \frac{\partial^2 F}{\partial v^2} (\sigma_v^2 v dt) + \frac{\partial^2 F}{\partial S \partial v} (\rho \sigma_v v S dt) \end{aligned}$$

Átrendezve:

$$\begin{aligned} dU &= \left[\frac{\partial F}{\partial t} + r S \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] dt + \\ &\quad + \left[\sqrt{v} S \frac{\partial F}{\partial S} dW_1 + \sigma_v \sqrt{v} \frac{\partial F}{\partial v} dW_2 \right] \end{aligned}$$

Valójában a no arbitrage feltétele miatt tudjuk, hogy ennek a várható értékének meg kell egyeznie a kockázatmentes kamatlábbal. Ehhez be kell látnunk, hogy a második zárójelben lévő összeg martingál. Annyinak kell igaznak lelhnie, hogy a sztochasztikus integrálnak nem szabad hogy mértékszivárgása legyen, ami abszolút megtörténhet, mivel a Heston-modell a variancia változása miatt egy kevert normális eloszlású súlyfüggvényt ad. Vagyis amennyiben teljesül, hogy nincs mértékszivárgás, folyamat sztochasztikus integrálja martingál.

A második momentum stabilitásának paraméteres feltételei

A kérdés tehát az, hogy igaz-e, hogy

$$E((\int_0^T SdW)^2) < \infty$$

Alkalmazzuk az Andersen–Piterbarg (2007) tételt 34-35. oldal <https://link.springer.com/article/10.1006-0011-7> a standard Heston-modell jelöléseire:

- A vizsgált momentum: $\omega = 2$
- Az árfolyam diffúziós szorzója: $\lambda = 1$
- A variancia volatilitása: $\varepsilon = \sigma_v$

Először határozzuk meg a tétel konstansát:

$$k = \frac{\lambda^2}{2}\omega(\omega - 1) = \frac{1^2}{2}2(2 - 1) = 1$$

A tétel szerinti paraméterek:

$$b = \frac{2k}{\varepsilon^2} = \frac{2}{\sigma_v^2}$$

$$a = \frac{2(\rho\varepsilon\lambda\omega - \kappa)}{\varepsilon^2} = \frac{2(\rho\sigma_v(1)(2) - \kappa)}{\sigma_v^2} = \frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2}$$

A diszkrimináns ($D = a^2 - 4b$) felírása:

$$D = \left(\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2}\right)^2 - \frac{8}{\sigma_v^2} = \frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4}$$

A tétel (1)-es pontja alapján a (T^*) (ami gyakorlatilag az időt mutatja, amíg a bizonyos ω momentum létezik) akkor lesz végtelen, ha $a < 0$ és $D \geq 0$ egyszerre teljesül.

Az $a < 0$ feltétel jelentése:

$$\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2} < 0 \quad \implies \quad 2\rho\sigma_v < \kappa$$

Mivel a mean-reversion sebesség $\kappa > 0$, és mivel jellemzően $\rho \leq 0$, ez az egyenlőtlenség a gyakorlatban szinte mindig triviálisan teljesül.

A $D \geq 0$ feltétel jelentése:

$$\frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4} \geq 0 \implies (\kappa - 2\rho\sigma_v)^2 \geq 2\sigma_v^2$$

Gyökvonás után (tudva, hogy a bal oldal az $a < 0$ miatt pozitív):

$$\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$$

Amennyiben a piacról kalibrált paraméterek kielégítik a $\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$ egyenlőtlenséget, a tétel (1)-es esete lép életbe, azaz a momentum-robbanás kritikus időpontja $T^* = \infty$.

Mivel bármely árazandó opció lejáratát (T) egy véges szám, a $T < T^*$ feltétel ($T < \infty$) automatikusan teljesül. Ez szigorúan bizonyítja, hogy az $\mathbb{E}[S_t^2]$ a teljes árazási horizonton véges marad. Innen tudjuk, hogy mivel véges, fennáll rá a Fubini-tétel,

$$\int_0^T \mathbb{E}[S_t^2] dt = \mathbb{E}\left(\int_0^T S^2 dt\right) < \infty$$

vagyis az integrál véges. Ezzel kizártuk a mértékszivárgást, így a Heston modell árfolyamata martingál, azaz igaz, hogy jelen esetben

$$\frac{\partial F}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 F}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 F}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 F}{\partial v^2} + rS\frac{\partial F}{\partial S} + \kappa(\theta - v)\frac{\partial F}{\partial v} + S\frac{\partial F}{\partial A} - rF = 0$$

Architektúra A jelen dolgozat célja egy olyan kifejlesztett PINN bemutatása, ami betanítás után, X ismeretével konstans időben árazza, valamint számolja ki a fedezéshez szükséges görögöket.

Ezt úgy teszi meg, hogy gyakorlatilag egy veszteségfüggvényt minimalizál úgy, hogy becsül egy megoldást, és a becsült megoldás behelyettesítésével és a valódi megoldás értéke közötti átlagos négyzetes hibát veszi veszteségnek.

Peremfeltételek a PINN modellben.

A parciális differenciálegyenletek megoldása során a peremfeltételek határozzák meg a rendszer viselkedését a vizsgált tartomány határain. A PINN architektúrákban ezeket a feltételeket nem merev korlátokként, hanem a veszteségfüggvény büntetőtagjaiként (MSE, vagyis átlagos négyzetes eltérés) érvényesítjük.

$S_\tau = 0$ peremfeltétel

Ha a részvény árfolyama nullára esik egy τ időpontban ($S = 0$), akkor, $S_{t>\tau}$ időpontban is 0 lesz, hiszen a folyamat driftje, és volatilitása is arányos S -sel, így onnan már nem tud elmozdulni. Így az opció kifizetése :

$$\left(\frac{1}{T}A_T - K\right)^+ = \left(\frac{1}{T}A_\tau - K\right)^+$$

lesz.

Mivel ezek a τ időpontok különbözőek lehetnek, és itt

$$\hat{F}(t, S_t, A_t, v_t) = \hat{F}(\tau, 0, A_\tau, v_\tau),$$

Bár a kifizetés pontos összege már a τ pillanatban ismertté válik, maga a pénzáramlás (a szerződés teljesítése) csak a T lejáratkor történik meg.

Emiatt a τ időpontban az opció reális piaci értékét a jövőbeli biztos kifizetés jelenértéke határozza meg. A hátralévő $T - \tau$ várakozási időre alkalmaznunk kell az $e^{-r(T-\tau)}$ diszkontfaktort

2. Neumann-peremfeltétel

A Carl Neumann (1832–1925) által bevezetett feltétel nem a függvény értékét, hanem valamely deriváltját határozza meg a peremen. Fizikai analógiája a peremen megadott hőáramlás (például képzeljünk el egy tökéletes szigetelést, ahol ugye a hőáramlás deriváltja nulla).

A Heston-modellben a felső peremen $S \rightarrow \infty$, (gyakorlatban $S = S_{max}$) Neumann-feltételt használunk. Amikor a részvény ára extrém magasra nő, az opció majdnem biztosan le lesz hívva, így átlag megegyezik az Árfolyammal. Ekkor ez egy lineáris függvény, mivel az opció lehívásra kerül, melynek második deriváltja (vagyis az opció Gammája) nulla. Ezt a másodrendű Neumann-feltételt így formalizáljuk:

$$\frac{\partial^2 F}{\partial S_{max}^2} = 0$$

A PINN architektúrában az automatikus differenciálás segítségével az (háló kimenetének) S szerinti második deriváltját közvetlenül beépítjük a veszteségfüggvénybe.

$$Loss_{S_{max}} = \frac{1}{N_{perem}} \sum_{i=1}^{N_{perem}} \left(\left. \frac{\partial^2 \hat{F}}{\partial S^2} \right|_{S_i=S_{max}} - 0 \right)^2$$

A modell teljes veszteségfüggvénye ezen peremfeltételek, a belső pontokon kiértékelt PDE reziduális, valamint a lejáratkori ($t = T$) kifizetési végfeltétel (Terminal condition) hibáinak összegeként áll elő. Ekkor a veszteségfüggvény:

$$\mathcal{L}_{loss} = \mathcal{L}_{pde} + \mathcal{L}_{ic} + \mathcal{L}_{Smax} + \mathcal{L}_{Smin}$$

ahol F a valódi értéket, $\widehat{F}$ jelölés a becsült értéket jelenti, és

$$\mathcal{L}_{pde} = MSE\left(\frac{\partial \widehat{F}}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 \widehat{F}}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 \widehat{F}}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 \widehat{F}}{\partial v^2} + rS\frac{\partial \widehat{F}}{\partial S} + \kappa(\theta - v)\frac{\partial \widehat{F}}{\partial v} + S\frac{\partial \widehat{F}}{\partial A} - r\widehat{F}\right)$$

$$\mathcal{L}_{ic} = MSE(\widehat{F}_{ic} - (\frac{1}{T}A_T - K))$$

$$\mathcal{L}_{Smin} = MSE(\widehat{F_{Smin}} - (\frac{1}{T}A_{\tau_0} - K))$$

$$\mathcal{L}_{Smax} = MSE\left(\frac{\partial^2 \widehat{F}}{\partial S_{max}^2}\right)$$

Ezenkívül, beleraktam még egy Monte Carlo szimulációt, egyrészt azért, hogy T időponton kívül $t = 0$ időpontban is legyenek adataink, azért hogy a hálónak legyenek viszonyítási pontjai az áfolyamintervallumon kívül az időintervallum mindkét végén is. Továbbá így jobban rá tud tanulni a valós árra a kezdő időpontban is.

A 0. időpontban egyenletesen generáltam 2000 árat (S_0) 0.01, és 3 között, és generáltam 2000 varianciát (v_0) 0.0001, és 0.6 között. Mindegyik kezdőár és variancia párosra lefuttattam 20000, 100 egyenlő lépésre diszkretizált utat, a Heston modell diszkretizált árfolyam dinamikája szerint. Így kiszámoltam 2000 kezdőár és variancia párosra az opció árát a 0. időpontban.

Ezután beleraktam valamilyen súlyokat (λ) az új veszteségfüggvénybe:

$$\mathcal{L}_{loss} = \lambda_1 \mathcal{L}_{pde} + \lambda_2 \mathcal{L}_{ic} + \lambda_3 \mathcal{L}_{Smax} + \lambda_4 \mathcal{L}_{Smin} + \lambda_5 \mathcal{L}_{MC}$$

Itt az

$$\mathcal{L}_{MC} = MSE(F_{MC} - \widehat{F_{MC}})$$

A lambda értékeket az alábbiak szerint határoztam meg:

$$\lambda_1 = 10, \lambda_2 = 7, \lambda_3 = 1, \lambda_4 = 1, \lambda_5 = 1$$

1. A hálózati architektúra

A tanítást egy NVIDIA GeForce RTX 3090-os processzoron végeztem el, amely 24GB VRAM-al rendelkezik. Mivel 4 dimenziós a probléma, ezért sok pontot kellett megvizsgálnom. Dimenzióként 100 pontból szerettem volna betanítani a függvényt, így $1 \cdot 10^{2 \cdot 4}$ -ra lőttem be a vizsgálandó pontok számát.

A hálóm 7 darab lineáris függvényt és 6 darab aktivációs függvényt tartalmaz, egymásba ágyazva, az utolsó lineáris függvény után értetlemszerűen már nincs aktivációs függvény. A lineáris függvények 4×256 , 256×256 , 256×256 , 256×256 , 256×256 , 256×128 , 128×1 méretűek.

Aktivációs függvénynek LAAF-tanh-t választottam (Locally Adaptive Activation Function) amely úgy néz ki, hogy:

$$\frac{e^{nx} - e^{-nx}}{e^{nx} + e^{-nx}}$$

ahol n egy tanulható paraméter, ami úgy tanul, hogy kiszámolja az $\frac{\partial \mathcal{L}_{loss}}{\partial n}$ -t és eszerint a gradiens szerint növeli, vagy csökkenti az n paramétert úgy, hogy a hibát minimalizálja.

1.1. Adatok skálázása

A bemeneti változók normalizálása nem csupán a PINN architektúrák, hanem általánosságban minden neurális hálózat betanításának egyik legfontosabb alapfeltétele. A Heston-Asian modell paraméterei nagyságrendileg jelentősen eltérnek egymástól: a variancia jellemzően nagyon kicsi ($v \in [0.0001, 0.6]$), míg a részvényárfolyam és az átlag nagyobb tartományt fed le ($S, A \in [0, 3]$).

Ha ezeket az adatokat nyers formában táplálnánk be a hálózatba, az két súlyos, a gépi tanulásban jól ismert problémához vezetne:

- **A veszteségfüggvény torzulása:** A bemenetek nagyságrendi különbségei miatt a hibafelületen a völgyek ellipszoid alakká torzulnának. Az optimalizáló algoritmus az egyik paramétert aránytalanul jobban és gyorsabban optimalizálná, míg a másik mentén alig haladna, ami instabil és rendkívül lassú konvergenciát eredményez.

- **Az aktivációs függvények szaturációja :** Az összetett függvényben tanh aktivációs függvényeket használunk, amelyek a nulla körüli tartományban a legaktívabbak (itt a legmeredekebb a deriváltjuk). A skálázatlan, nagy bemeneti értékek a neuronok kimenetét azonnal a tanh függvény lapos, végeire tolnák. Ez azért történik meg, mert

$$\tanh'(x) = 1 - \tanh^2(x)$$

, ami $x = 0$ -tól kezdve bármelyik irányba nagyon gyorsan konvergál 0, hoz. Ez azt eredményezi, hogy sokkal lassabban tanul a háló, már nagyságrendileg közel lévő értékek esetén is.

A PINN-ek esetében ez az általános gépi tanulási szabály hatványozottan fontos. Mivel a PDE reziduális kiszámításához másodrendű deriváltakra is szükség van, az első deriváltakhoz való konvergálásuk miatt megszünteti a másodrendű deriváltakat.

Ennek elkerülése érdekében egy skálázó objektumot alkalmaztam, amely minden fizikai bemeneti dimenziót szigorúan a $[-1, 1]$ zárt intervallumra transzformál az alábbi normalizáció segítségével. Egy tetszőleges x bemenetre a transzformáció képlete:

$$x_{scaled} = 2 \frac{x - x_{min}}{x_{max} - x_{min}} - 1$$

A neurális háló kizárólag ezeken a normalizált értékeken operál. Így az optimalizációs tér topológiája gömbszerűbbé, kiegyensúlyozottabbá válik, az aktivációs függvények pedig az aktív tartományukban maradnak. Megjegyzendő, hogy a PDE kiértékelésekor az automatikus differenciálás láncszabálya miatt a deriváltakat a fentebb bemutatott skálázás inverzével megfelelően korrigálni kell, hogy a PDE érvényes maradjon.

1.2. Mintavételezés: Latin Hypercube Sampling (LHS)

A fizikai tér letapogatása során egy 4 dimenziós tartományt kell lefednünk. A klasszikus, egyenletes rácspontos felosztás miatt exponenciálisan növekvő adathalmazt eredményezne, míg a tisztán egyenletes mintavétel során a pontok hajlamosak csomósodni, nagy, üresen tátongó lyukakat hagyva a 4 dimenziós térben.

Ezen probléma áthidalására a Latin Hypercube Sampling algoritmust alkalmaztam. Az LHS úgy működik, hogy minden dimenziótengely mentén N egyenlő valószínűségű intervallumra osztja a teret, és garantálja, hogy minden egyes többdimenziós intervallumból pontosan egy pont kerüljön kiválasztásra.

A modellünkben a mintavételező algoritmus (a kódban: Sampler) ezt kiegészíti egy a pontokat a strike price köré sűrítő transzformációval is az S és A tengelyek mentén, hiszen a deriváltak (például az opció Gammája) itt a legnagyobbak és legnehezebben tanulhatók.

1.3. Kétfázisú optimalizáció és dinamikus rács

1. Fázis: Dinamikus Adam optimalizáció

Az első szakaszban az Adam optimalizálót használjuk, amely jól kezeli a zajos, komplex felületeket. A 4 dimenziós (t, S, v, A) fázistér letapogatása során egy komoly hardveres korlátba ütköztem: a rendelkezésre álló grafikus kártya memóriája (24 GB VRAM) nem teszi lehetővé, hogy a tér lefedéséhez szükséges több tízmillió pontot egyidejűleg a memóriában tartson, és azokon másodrendű deriváltakat számoljon.

Ezt a problémát egy dinamikus mintavételezési stratégiával hidaltam át, amely a hardveres problémát megoldja. Annak érdekében, hogy a memória ne teljen meg, de a hálózat a tér lehető legnagyobb részéből vegyen mintát, minden egyes epoch elején 25 000 teljesen új ponton generáltattam a térben.

Ez a folyamatos újra-mintavételezés garantálja, hogy bár a VRAM terhelése alacsony marad, a több ezer epoch alatt a hálózat folyamatosan friss, korábban nem látott pontokkal találkozik a folytonos térből.

A betanításba beépítettem egy bemelegítő fázist is. Az első 1000 epoch során a parciális differenciálegyenlet büntetőtagjának súlyát (λ_{pde}) nullára állítottam. A PDE kikapcsolásával a hálózat először közelítőleg megtanulja a fontos peremfeltételeket.

2. Fázis: L-BFGS másodrendű finomhangolás

Sajnos az adam optimizér, a globális minimum közvetlen közelében hajlamos oszcillálni. A hajszálpontos árazás, és a görögök számítása érdekében a tanítást az L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno) algoritmussal zártam.

Az L-BFGS a Hesse-mátrix inverzét közelíti, így figyelembe veszi a hibafelület görbületét is, ami rendkívül gyors és precíz konvergenciát biztosít a minimum pont felé. Mivel ez a módszer line search-t alkalmaz, így egy adott

irányban többször is kiértékeli a függvényt, ezért a mintavételezési pontoknak szigorúan statikusnak kell lenniük. Ezért ebben a fázisban egy hatalmas, fix pontokból álló rácsot (50 000 belső pont és perempontok) szögeztem le, és ezen végeztem el az utolsó iterációkat, garantálva a PDE reziduálisok maximális kisimítását.

Így gyakorlatilag az első fázis megkereste elég jól a globális minimum környékét, a második fázis pedig a globális minimumot.