

Ázsiai Opciók árazása Heston-modellben Physics Informed Neural Network segítségével

Wunderlich Ábris

Bevezetés, dolgozat célja.

Az egzotikus opciók árazása a modern pénzügyi matematika egyik legösszetettebb területe, különösen akkor, ha sztochasztikus volatilitással és útfüggő kifizetési struktúrákkal dolgozunk. Dolgozatomban Heston-modellben fogom az ázsiai opciókat beárazni, és a görögjeit kiszámolni. Hasonló munkák születtek már, például [Park et al., 2025] Black-Scholes modell alatt áraztak ázsiai opciókat PINN-nel, míg [Hainaut and Casas, 2024] európai opciót áraztak Heston-modell alatt PINN-nel.

Az ázsiai opciók kifizetése az eszköz árfolyamának egy meghatározott időszak alatti átlagától függ. A számtani átlagolású, rögzített kötési árfolyamú call opció esetében a kifizetési függvény a lejáratú időpontban az árfolyam időbeli integrálján alapul. A kifizetési függvény (ami a PDE megoldásának végfeltételeként szolgál), a következőképpen írható fel:

$$F(T, S, v, A) = \max \left(\frac{1}{T} \int_0^T S_\tau d\tau - K, 0 \right), \text{ ahol } A = \int_0^T S_\tau d\tau$$

Ebben a struktúrában a K jelöli a kötési árfolyamot, a T pedig a lejáratot.

A Heston-modell alatt árazott Ázsiai opció beárazása egy négydimenziós parciális differenciálegyenlet megoldását követeli meg, ami a hagyományos numerikus eljárások számára jelentős kihívást jelent. Ebbe a környezetbe érkeznek meg a Physics-Informed Neural Network (PINN) modellek, amelyek alapvetően változtatják meg a problémához való hozzáállásunkat azáltal, hogy a neurális hálózatok univerzális közelítő erejét ötvözik a pénzügyi matematika törvényszerűségeivel. A PINN lényege, hogy a modell tanítása során a veszteségfüggvénybe közvetlenül beágyazzuk magát a differenciálegyenlet rendszert, így a hálózat nem csupán adatokat interpolál, hanem megtanulja a mögöttes dinamikát is. A módszer egyik legnagyobb előnye a hagyományos rács-alapú eljárásokkal, például a véges differencia módszerrel szemben, az árfelület folytonossága. Míg az FDM csak véges számú ponton képes megadni a megoldást, addig a PINN hálómentes architektúrája lehetővé teszi, hogy tetszőleges pontokon kapjuk meg a megoldást, így magas dimenziószám mellett is skálázható marad. A Monte Carlo szimulációkkal összevetve a PINN egy folytonos és sima becslőfüggvényt eredményez, lassú a betanítása viszont utána konstans időbeli kiértékelésre képes, kiküszöbölve a szimulációkra jellemző statisztikai zajt és lassú konvergenciát. Különösen értékes tulajdonság az automatikus differenciálás lehetősége, amely révén az opciós görögök, mint a Delta vagy a Gamma, nagy pontossággal, és extra számítási költség nélkül konstans időben nyerhetők ki a hálóból, elkerülve a diszkrét lépések miatt létrejövő numerikus deriválást.

1. Matematikai Keretrendszer

Ebben a fejezetben az a célunk eljutni az Ázsiai opciók árát leíró parciális differenciálegyenlet-rendszerhez, és ezáltal azt is vizsgálni, hogy milyen modellre jellemző paraméterek mellett működik a modell jól, hogy tudjuk, mely paraméterek mellett lesz jó a modell szerint tanuló PINN-em.

Tegyük fel, hogy a pénzügyi piacokra teljesül az NFLVR. (No Free Lunch with Vanishing Risk) Ekkor Delbaen–Schachermayer tétel szerint létezik ekvivalens lokális martingálmérték Q , ami szükséges, és elégséges feltétele az arbitrázsmentességhez. Mivel két Wiener-folyamat hajtja a dinamikát, és csak egy kockázatos eszközünk van, ezért a piac nem teljes, azaz a pénzügyi matematika második alaptétele nem áll fenn rá, azaz nem egyértelmű az ekvivalens martingálmérték ($Q \sim P$)

1.1 A Kiinduló Sztochasztikus Differenciálegyenletek

A levezetést a valós mérték (P) szerinti dinamikákból indítjuk. Az S_t a részvényárfolyam, v_t a variancia, A_t pedig az ázsiai opcióhoz szükséges Átlagár T-szerese.

Részvényárfolyam dinamikája

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_{1,t}$$

ahol μ a valós várható hozam.

Variancia dinamikája

$$dv_t = \kappa(\theta - v_t)dt + \sigma_v \sqrt{v_t} dW_{2,t}$$

Integrál dinamikája

Mivel $A_t = \int_0^t S_u du$, ennek differenciálja tisztán determinisztikus (nincs benne dW):

$$dA_t = S_t dt$$

Korrelációs szabály

A két Wiener-folyamat közötti kapcsolat:

$$dW_{1,t} dW_{2,t} = \rho dt$$

1.2 Mértékcseré

A kockázatmentes árazás alapelve, hogy a diszkontált részvényárfolyamnak ($e^{-rt} S_t$) lokális martingálnak kell lennie a Q mérték alatt, azaz a drift rS_t . Ebből meghatározható az árfolyamkockázat piaci ára, λ_1 :

$$\mu - \lambda_1 \sqrt{v_t} = r \quad \implies \quad \lambda_1 = \frac{\mu - r}{\sqrt{v_t}}$$

Itt egy fontos technikai feltételt kell rögzítenünk: mivel a λ_1 kockázati prémium kifejezésének nevezőjében a variancia gyöke szerepel, a mértékcserét definiáló sűrűségfolyamat martingál tulajdonsága sérülhet. Ha azonban fennáll a Feller-feltétel, azaz

$$2\kappa\theta \geq \sigma_v^2$$

akkor a volatilitás véges időn belül szigorúan pozitív marad. Ebben az esetben a mértékcseré folyamat várható értéke pontosan 1 lesz

([Wong and Heyde, 2006] Theorem 3.5), azaz martingál lesz. Ennek fényében áttérhetünk a Q lokális martingálmértékre, ahol a kereskedhető eszköz dinamikája:

$$dS_t = rS_t dt + \sqrt{v_t} S_t d\widetilde{W}_{1,t}$$

Az árazáshoz elengedhetetlen a varianciafolyamat Q alatti dinamikájának meghatározása is. A szakirodalmat követve [Wong and Heyde, 2006] a mértékcseré után:

$$dv_t = \kappa^*(\theta^* - v_t)dt + \sigma_v \sqrt{v_t} d\widetilde{W}_{2,t}$$

lesz, ahol a kockázatmentes mérték alatti paraméterek κ^* , θ^* a cikk szerint (ezentúl ezeket csillag nélkül fogom használni a jelölés egyszerűsítése kedvéért. Ezzel a (S_t, v_t) dinamikája jól definiált a Q mérték alatt.

1.3 A Bizonyítandó Parciális Differenciálegyenlet

A cél, hogy eljussunk az alábbi PDE-ig:

$$\begin{aligned} \frac{\partial U}{\partial t} + \frac{1}{2}vS^2 \frac{\partial^2 U}{\partial S^2} + \rho\sigma_v vS \frac{\partial^2 U}{\partial S \partial v} + \frac{1}{2}\sigma_v^2 v \frac{\partial^2 U}{\partial v^2} \\ + rS \frac{\partial U}{\partial S} + \kappa^*(\theta^* - v_t) \frac{\partial U}{\partial v} + S \frac{\partial U}{\partial A} - rU = 0 \end{aligned}$$

Tudjuk, hogy a Girsanov-tétel alkalmazása után az arbitrázsmentesség miatt: A Q mérték alatt az opció értékének teljes várható növekménye megegyezik az opcióba fektetett tőke futamidő alatti, kockázatmentes rátával vett elvárt hozamával:

$$E^Q[F(X_T) - F(X_t) \mid \mathcal{F}_t] = E^Q \left[\int_t^T rF(X_s) ds \mid \mathcal{F}_t \right]$$

Tétel: Itô-formula: Ha F kétszer folyamatosan deriválható n -változós függvény, és $(X_k)_{k=1}^n$ folytonos szemimartingálók, akkor tetszőleges t időpontra:

$$F(X(T)) - F(X(t)) = \sum_{k=1}^n \int_t^T \frac{\partial F}{\partial x_k}(X(s)) dX_k(s) + \frac{1}{2} \sum_{i,j} \int_t^T \frac{\partial^2 F}{\partial x_i \partial x_j}(X(s)) d[X_i, X_j](s).$$

Látható, hogy a Jobboldalon az első tag egy sztochasztikus integrál, a $dX_k(s)$ miatt, a második, pedig egy sima Stieltjes, a kvadrátikus variáció miatt.

Ez azt jelenti az Itô-formula szerint, hogy egy lokális martingál szerinti kétszer folytonosan differenciálható függvény egy sztochasztikus integrál (vagyis lokális martingál), és egy korlátos függvény összegeként áll elő, vagyis egy szemimartingál.

Használjuk az Ito-formula definícióját.

$$\begin{aligned}
F(X(T)) - F(X(t)) &= \int_t^T \frac{\partial F}{\partial S} dS + \int_t^T \frac{\partial F}{\partial v} dv + \int_t^T \frac{\partial F}{\partial A} dA + \int_t^T \frac{\partial F}{\partial t} ds + \\
&+ \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S^2} d[S, S] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial v^2} d[v, v] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A^2} d[A, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial t^2} d[s, s] + \\
&\frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial A} d[S, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial t} d[S, s] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial v} d[S, v] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A \partial t} d[A, s] \\
&+ \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A \partial v} d[v, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial t \partial v} d[s, v]
\end{aligned}$$

Triviális, hogy azok a kvadratikus variációs tagok, amelyekben t van 0 - t adnak, így azok kiesnek, valamint $dA = Sds$ miatt ugyanez igaz az A -s tagokra is.

Most nézzük meg a maradék kvadratikus variációs tagokat, 3 tagot kell megvizsgálnunk.:

$$\int_t^T \frac{\partial^2 F}{\partial S^2} d[S, S] = \int_t^T \frac{\partial^2 F}{\partial S^2} [\mu S_s ds + \sqrt{v_s} S_s dW_{1,s}] \stackrel{[W,s],[s,s]=0}{=} \int_t^T \frac{\partial^2 F}{\partial S^2} v_s S_s^2 ds$$

A fentebbi indoklás miatt ugyanúgy:

$$\int_t^T \frac{\partial^2 F}{\partial v^2} d[v, v] \stackrel{[W,s],[s,s]=0}{=} \int_t^T \frac{\partial^2 F}{\partial v^2} \sigma_v^2 v_s ds$$

Most nézzük meg $[v, S]$ -t:

$$\begin{aligned}
d[S, v] &= (\mu S_s ds + \sqrt{v_s} S_s dW_{1,s}) (\kappa(\theta - v_s) ds + \sigma_v \sqrt{v_s} dW_{2,s}) \stackrel{[W,s],[s,s]=0}{=} \\
&\sqrt{v_s} S_s dW_{1,s} \sigma_v \sqrt{v_s} dW_{2,s} = S_s \sigma_v v_s \rho ds
\end{aligned}$$

Azaz:

$$\int_t^T \frac{\partial^2 F}{\partial S \partial v} d[S, v] = \int_t^T \frac{\partial^2 F}{\partial S \partial v} S_s \sigma_v v_s \rho ds$$

. Behelyettesítve az SDE-ket:

$$\begin{aligned}
dF_s &= \frac{\partial F}{\partial S} (r S ds + \sqrt{v} S dW_1) + \frac{\partial F}{\partial v} (\kappa(\theta - v) ds + \sigma_v \sqrt{v} dW_2) + \frac{\partial F}{\partial A} (S ds) + \frac{\partial F}{\partial t} ds + \\
&+ \frac{1}{2} \frac{\partial^2 F}{\partial S^2} (v S^2 ds) + \frac{1}{2} \frac{\partial^2 F}{\partial v^2} (\sigma_v^2 v ds) + \frac{\partial^2 F}{\partial S \partial v} (\rho \sigma_v v S ds)
\end{aligned}$$

Átrendezve:

$$\begin{aligned}
dF_s &= \\
&\left[\frac{\partial F}{\partial t} + r S \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds \\
&+ \left[\sqrt{v} S \frac{\partial F}{\partial S} dW_1 + \sigma_v \sqrt{v} \frac{\partial F}{\partial v} dW_2 \right]
\end{aligned}$$

Most már csak annyit kell belátnunk, hogy a második zárójelben lévő összeg martingál.

Ehhez annyinak kell igaznak lennie, hogy a sztochasztikus integrálnak nem szabad hogy mértékszivárgása legyen, ami abszolút megtörténhet, mivel a Heston-modell a variancia sztochasztikus változása miatt egy kevert normális eloszlású súlyfüggvényt ad. Vagyis amennyiben teljesül, hogy nincs mértékszivárgás, folyamat sztochasztikus integrálja martingál.

1.3.1 A Sztochasztikus integrálok második momentumainak létezésének feltételei

A kérdés tehát az, hogy igaz-e, hogy

$$E \left(\int_t^T v_s S_s^2 \left(\frac{\partial F}{\partial S} \right)^2 ds \right) < \infty$$

Tegyük fel, hogy teljesül európai call opciókra Heston-modellben, a peremfeltétel miatt hogy $0 \leq \frac{\partial F}{\partial S} \leq 1$. Ekkor, mivel az Ázsiai opcióknak az árrugalmassága az átlag figyelembevétel miatt nem akkora mint az európai opcióknak, fennáll hogy $v S^2 \left(\frac{\partial F}{\partial S} \right)^2 \leq v S^2$. Továbbá, még azt is észre lehet venni, hogy

$$(dS_s)^2 = d[S, S] = ((\mu S_s ds + \sqrt{v_s} S_s dW_{1,s})(\mu S_s ds + \sqrt{v_s} S_s dW_{1,s})) = v S^2 ds$$

amiben észrevehetjük, ha szemfülesek vagyunk, hogy a $d[S, S]$ az Ito lemma kvadratikus variációs tagja amennyiben a $d(S_s^2)$ -t nézzük:

$$d(S_s^2) = 2S \bullet S + 2 \frac{1}{2} d[S, S] = v S^2 ds + 2S(r S ds + \sqrt{v} S dW) = (v + 2r) S^2 ds + \sqrt{v} S dW$$

Azaz:

$$\begin{aligned} E(S_T^2 - S_t^2) &= E \left(\int_t^T (v + 2r) S^2 ds \right) + E \left(\int_t^T \sqrt{v} S dW \right) = \\ &= E(S_T^2) - S_t^2 = E \left(\int_t^T v S^2 ds \right) + E \left(2r \int_t^T S^2 ds \right) + E \left(\int_t^T \sqrt{v} S dW \right) \end{aligned}$$

Fubini, és $E \left(2r \int_t^T S^2 ds \right)$ Átvitele a baloldalra:

$$E \left(\int_t^T v S^2 ds \right) = E(S_T^2) - S_t^2 - E \left(2r \int_t^T S^2 ds \right)$$

Most azt kell belátnunk, hogy

$$E \left(\int_t^T S^2 ds \right) < \infty$$

Alkalmazzuk [Andersen and Piterbarg, 2007] tételt 34-35. a standard Heston-modell jelöléseire:

- A vizsgált momentum: $\omega = 2$
- Az árfolyam diffúziós szorzója: $\lambda = 1$
- A variancia volatilitása: $\varepsilon = \sigma_v$

Először határozzuk meg a tétel konstansát:

$$k = \frac{\lambda^2}{2} \omega(\omega - 1) = \frac{1^2}{2} 2(2 - 1) = 1$$

A tétel szerinti paraméterek:

$$\begin{aligned} b &= \frac{2k}{\varepsilon^2} = \frac{2}{\sigma_v^2} \\ a &= \frac{2(\rho \varepsilon \lambda \omega - \kappa)}{\varepsilon^2} = \frac{2(\rho \sigma_v(1)(2) - \kappa)}{\sigma_v^2} = \frac{4\rho \sigma_v - 2\kappa}{\sigma_v^2} \end{aligned}$$

A diszkrimináns ($D = a^2 - 4b$) felírása:

$$D = \left(\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2} \right)^2 - \frac{8}{\sigma_v^2} = \frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4}$$

A tétel (1)-es pontja alapján a (T^*) (ami gyakorlatilag az időt mutatja, amíg a bizonyos ω momentum létezik) akkor lesz végtelen, ha $a < 0$ és $D \geq 0$ egyszerre teljesül. Az $a < 0$ feltétel jelentése:

$$\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2} < 0 \implies 2\rho\sigma_v < \kappa$$

Mivel a mean-reversion sebesség $\kappa > 0$, és mivel jellemzően $\rho \leq 0$, ez az egyenlőtlenség a gyakorlatban szinte mindig triviálisan teljesül. A $D \geq 0$ feltétel jelentése:

$$\frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4} \geq 0 \implies (\kappa - 2\rho\sigma_v)^2 \geq 2\sigma_v^2$$

Gyökvonás után (tudva, hogy a bal oldal az $a < 0$ miatt pozitív):

$$\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$$

Amennyiben a piacról kalibrált paraméterek kielégítik a $\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$ egyenlőtlenséget, a tétel (1)-es esete lép életbe, azaz a momentum-robbanás kritikus időpontja $T^* = \infty$. Mivel bármely árazandó opció lejárata (T) egy véges szám, a $t \leq T < T^*$ feltétel ($T < \infty$) automatikusan teljesül. Ez szigorúan bizonyítja, hogy az $E[S_s^2]$ a teljes árazási horizonton véges marad. Innen tudjuk, hogy mivel véges, véges időhorizonton az integrálja is az, fennáll rá a Fubini-tétel,

$$\int_t^T E[S_s^2] ds = E \left(\int_t^T S_s^2 ds \right) < \infty$$

vagyis az integrál véges. Azaz:

$$E \left(\int_t^T v_s S_s^2 ds \right) < \infty$$

Nézzük a másik tagot!

$$E \left(\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s} \right)^2 ds \right) < \infty$$

Nézzük meg a vizsgálandó kifejezést:

$$E \left[\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s} \right)^2 ds \right]$$

. Ehhez először $\frac{\partial F}{\partial v_t}$ korlátosságát kell belátnunk.

Az európai opciókra igaz, hogy [Ekström and Tysk, 2006] 6. oldal, 3.2 Propositionja szerint Az F opciós ár $C^{2,2,1}((0, \infty)^2 \times [0, T])$ osztályú, és kielégíti az

$$F_t + \mathcal{L}F = 0$$

egyenletet minden $(S, v, t) \in (0, \infty)^2 \times [0, T]$ pontban.

Ez azt jelenti, hogy nincs szingularitása az Opció árának, kétszer folytonosan differenciálható így ahogy ezt a 8. oldalon a proposition 4.2-ban meg is jegyzi, $\frac{\partial F}{\partial v_t}$ folytonos $v_t = 0$ -ig.

[Cox et al., 1985] 391. oldala alapján:

$$dv_t = \kappa(\theta - v_t)dt + \sigma_v \sqrt{v_t} dW_{2,t}$$

folyamatban a v_t elérheti a nullát, ha $\sigma^2 > 2\kappa\theta$. Ha $2\kappa\theta \geq \sigma^2$, a felfelé irányuló drift elég nagy ahhoz, hogy az origót elérhetetlenné tegye. Mindkét esetben a volatilitás soha nem válhat negatívvá. Ha a volatilitás eléri a nullát, azt követően csak növekedni tud, mivel a $\kappa\theta$ drift ekkor pozitív, a $\sigma^2 v$ variancia pedig nulla. Ez biztosítja, hogy egy nemnegatív volatilitás az is maradjon.

Mivel feltettük a Feller feltételt, ezért tudjuk hogy v_t sosem lesz 0.

Ezekből már arra tudunk következtetni, hogy mivel tudjuk, hogy az opció ára kétszer folytonosan differenciálható v_t szerint, ezért a vega folytonos, mivel az opció lejáratára véges, ezért $(t \mapsto v_t)$ egy kompakt intervallumon $([0, T])$ mindig korlátos. Mivel a Feller-feltétel miatt kizártuk $v_t = 0$ -t ezért a v_t kompakt. A Weierstrass-tétel miatt tudjuk, hogy folytonos függvény kompakt halmazon felveszi a maximumát, vagyis bebizonyítottuk, hogy a vega korlátos. Mivel az európai opció vegája felső korlátja az ázsiaiak, ezért tudjuk, hogy az ázsiai opció vegája is korlátos,

azaz létezik egy $M > 0$ konstans, amire $\left(\frac{\partial F}{\partial v_s}\right)^2 \leq M^2$, vagyis a fenti várható értékre igaz, hogy:

$$E \left[\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s} \right)^2 ds \right] \leq E \left[\int_t^T \sigma_v^2 v_s M^2 ds \right] \stackrel{Fubini}{=} \sigma_v^2 M^2 \int_t^T E[v_s] ds$$

Innen már könnyű, hiszen tudjuk, hogy a v_s egy CIR folyamat. A CIR folyamat várható értéke bármely s időpontban egy egzakt, ismert, véges kifejezés:

$$E[v_s] = \theta + (v_t - \theta)e^{-\kappa(s-t)}$$

Mivel az $E[v_s]$ függvény folytonos és véges, a véges $[t, T]$ intervallumon vett integrálja is garantáltan véges lesz. Tehát a teljes sztochasztikus integrál várható értéke automatikusan véges marad, így az Ito-formula dW_2 -höz tartozó tagja is valódi martingál lesz. Azaz az Ito-formula szerinti drift tag kinullázásával megkapjuk a keresett árazó parciális differenciálegyenletet. Ezzel kizártuk a mértékszivárgást, azaz igaz, hogy :

$$E^Q[F(X_T) - F(X_t)] = E^Q \left[\int_t^T rF(X_s) ds \right]$$

$$E^Q(dF) =$$

$$E^Q \left[\left[\frac{\partial F}{\partial t} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds \right] +$$

$$+ E^Q \left[\left[\sqrt{v} S \frac{\partial F}{\partial S} dW_1 + \sigma_v \sqrt{v} \frac{\partial F}{\partial v} dW_2 \right] \right]$$

martingál tul. miatt
 $\implies$

$$= E^Q \left[\left[\frac{\partial F}{\partial t} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds \right]$$

$$\stackrel{\text{arbitrázsmentesség}}{\implies} 0 = E^Q \left[\int_t^T dF_s - rF(X_s) ds \right] =$$

$$\frac{\partial F}{\partial t} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} - rF = 0$$

ami a PINN-emben a PDE lesz. A parciális differenciálegyenlet-rendszer peremfeltétele pedig:

$$\begin{cases} \frac{\partial F}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 F}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 F}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 F}{\partial v^2} + rS\frac{\partial F}{\partial S} + \kappa(\theta - v)\frac{\partial F}{\partial v} + S\frac{\partial F}{\partial A} - rF = 0 \\ F(T, S, v, A) = \max\left(\frac{A}{T} - K, 0\right), \text{ ha } t = T \end{cases}$$

lesz, ahol a a lejáratkori kifizetés a peremfeltétel.

1.4 Tételek alkalmazása a PINN-modellben

A jelen dolgozat célja egy olyan kifejlesztett PINN bemutatása, ami betanítás után, X ismeretével konstans időben árazza, valamint számolja ki a fedezéshez szükséges görögöket.

Ezt úgy teszi meg, hogy gyakorlatilag egy veszteségfüggvényt minimalizál úgy, hogy minden körben(epochban) becsül egy megoldást, egy függvény tetszőlegesen választott pontjaira, és a becsült megoldások behelyettesítésével és a valódi megoldások értékei közötti átlagos négyzetes hibát veszi veszteségnek.

1.4.1 Peremfeltételek a PINN modellben.

A parciális differenciálegyenletek megoldása során a peremfeltételek határozzák meg a rendszer viselkedését a vizsgált tartomány határain. A PINN architektúrákban ezeket a feltételeket nem merev korlátokként, hanem a veszteségfüggvény büntetőtagjaiként (MSE, vagyis átlagos négyzetes eltérés) érvényesítjük.

$S_\tau = 0$ peremfeltétel

Ha a részvény árfolyama nullára esik egy τ időpontban ($S = 0$), akkor, $S_{t>\tau}$ időpontban is 0 lesz, hiszen a folyamat driftje, és volatilitása is arányos S -sel, így onnan már nem tud elmozdulni. Így az opció kifizetése :

$$\left(\frac{1}{T}A_T - K\right)^+ = \left(\frac{1}{T}A_\tau - K\right)^+$$

lesz.

Mivel ezek a τ időpontok különbözőek lehetnek, és itt

$$\widehat{F}(t, S_t, A_t, v_t) = \widehat{F}(\tau, 0, A_\tau, v_\tau),$$

Bár a kifizetés pontos összege már a τ pillanatban ismertté válik, maga a pénzáramlás (a szerződés teljesítése) csak a T lejáratkor történik meg.

Emiatt a τ időpontban az opció piaci értékét a jövőbeli biztos kifizetés jelenértéke határozza meg. A hátralévő $T - \tau$ várakozási időre alkalmaznunk kell az $e^{-r(T-\tau)}$ diszkontfaktort. Megvalósítás tekintetében, nem a max függvényt raktam

$S_{max} \rightarrow \infty$ (Neumann-peremfeltétel)

A Carl Neumann (1832–1925) által bevezetett feltétel nem a függvény értékét, hanem valamely deriváltját határozza meg a peremen. Fizikai analógiája a peremen megadott hőáramlás (például képzeljünk el egy tökéletes szigetelést, ahol ugye a hőáramlás deriváltja nulla).

A Heston-modellben a felső peremen $S \rightarrow \infty$, (gyakorlatban $S = S_{max}$) Neumann-feltételt használunk. Amikor a részvény ára extrém magasra nő, az opció majdnem biztosan le lesz hívva, így átlag megegyezik az Árfolyammal. Ekkor ez egy lineáris függvény, mivel az opció le hívásra kerül, melynek második deriváltja (vagyis az opció Gammája) nulla. Ezt a másodrendű Neumann-feltételt így formalizáljuk:

$$\frac{\partial^2 F}{\partial S_{max}^2} = 0$$

A PINN architektúrában az automatikus differenciálás segítségével az (háló kimenetének) S szerinti második deriváltját közvetlenül beépítjük a veszteségfüggvénybe.

$$Loss_{S_{max}} = \frac{1}{N_{perem}} \sum_{i=1}^{N_{perem}} \left(\left. \frac{\partial^2 \hat{F}}{\partial S^2} \right|_{S_i=S_{max}} - 0 \right)^2$$

1.4.2 Veszteségfüggvény

Valójában ezek a peremfeltételek arra kellettek, hogy jó megoldásra tanuljon rá a PINN-em, mivel ugye a Heston-modell egy parabolikus PDE, azaz elvben végtelen megoldása van. Viszont a peremfeltételek garantálják, hogy egy megoldása legyen a parabolikus PDE-nek.

A modell teljes veszteségfüggvénye a peremfeltételek, a belső pontokon kiértékelt PDE reziduális, valamint a lejáratkori ($t = T$) peremfeltétel hibáinak összegeként áll elő. Ekkor a veszteségfüggvény:

$$\mathcal{L}_{loss} = \mathcal{L}_{pde} + \mathcal{L}_{ic} + \mathcal{L}_{S_{max}} + \mathcal{L}_{S_{min}}$$

ahol F a valódi értéket, $\hat{F}$ jelölés a becsült értéket jelenti, és

$$\mathcal{L}_{pde} =$$

$$MSE\left(\frac{\partial \hat{F}}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 \hat{F}}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 \hat{F}}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 \hat{F}}{\partial v^2} + rS\frac{\partial \hat{F}}{\partial S} + \kappa(\theta - v)\frac{\partial \hat{F}}{\partial v} + S\frac{\partial \hat{F}}{\partial A} - r\hat{F}\right)$$

$$\mathcal{L}_{ic} = MSE(\hat{F}_{ic} - Softplus(\frac{1}{T}A_T - K))$$

$$\mathcal{L}_{S_{min}} = MSE(\widehat{F_{S_{min}}} - Softplus(\frac{1}{T}A_{\tau_0} - K))$$

$$\mathcal{L}_{S_{max}} = MSE\left(\frac{\partial^2 \hat{F}}{\partial S_{max}^2}\right)$$

Ahol a Softplus függvény a hivatalos pytorch dokumentáció szerint:

[PyTorch Contributors, 2024] egy jó approximációja a ReLu függvénynek, ami a $\text{Max}(x, 0)$ függvény. Azért kell, mert a max függvény nem deriválható a 0 helyen, viszont deriválható függvények kellenek, hiszen a gradiens ereszkedés miatt elengedhetetlen ez a feltétel. A Softplus képlete:

$$Softplus(x) = \frac{1}{\beta} \ln(1 + e^{(\beta x)})$$

A β paramétert 20-nak választottam meg Ezenkívül, beleraktam még egy Monte Carlo szimulációt, egyrészt azért, hogy T időponton kívül $t = 0$ időpontban is legyenek adataink, azért

hogy a hálónak legyenek viszonyítási pontjai az árfolyamintervallumon kívül az időintervallum mindkét végén is. Továbbá így jobban rá tud tanulni a valós árra a kezdő időpontban is.

A 0. időpontban egyenletesen generáltam 2000 árat (S_0) 0.01, és 5 között, és generáltam 2000 varianciát (v_0) 0.0001, és 1 között. Mindegyik kezdőár és variancia párosra lefuttattam 20000, 100 egyenlő lépésre diszkretizált utat, a Heston-modell diszkretizált árfolyam dinamikája szerint. Így kiszámoltam 2000 kezdőár és variancia párosra az opció árát a 0. időpontban.

Ezután beleraktam valamilyen súlyokat (λ) az új veszteségfüggvénybe:

$$\mathcal{L}_{loss} = \lambda_1 \mathcal{L}_{pde} + \lambda_2 \mathcal{L}_{ic} + \lambda_3 \mathcal{L}_{Smax} + \lambda_4 \mathcal{L}_{Smin} + \lambda_5 \mathcal{L}_{MC}$$

Itt az

$$\mathcal{L}_{MC} = MSE(F_{MC} - \widehat{F_{MC}})$$

A lambda értékeket az alábbiak szerint határoztam meg:

$$\lambda_1 = 10, \lambda_2 = 7, \lambda_3 = 1, \lambda_4 = 1, \lambda_5 = 1$$

2. A hálózati architektúra

A tanítást egy NVIDIA GeForce RTX 3090-os processzoron végeztem el, amely 24GB VRAM-al rendelkezik. Mivel 4 dimenziós a probléma, ezért sok pontot kellett megvizsgálnom. Dimenzióként körülbelül 150 pontból szerettem volna betanítani a függvényt, így $5 \cdot 10^{2 \cdot 4}$ -ra lőttem be a vizsgálandó pontok számát.

2.1 Hálózat felépítése

A hálóm 7 darab lineáris függvényt és 6 darab aktivációs függvényt tartalmaz, egymásba ágyazva, az utolsó lineáris függvény után értelemszerűen már nincs aktivációs függvény. A lineáris függvények 4×256 , 256×256 , 256×256 , 256×256 , 256×256 , 256×128 , 128×1 méretűek.

Aktivációs függvénynek LAAF-tanh-t választottam (Locally Adaptive Activation Function) amely úgy néz ki, hogy:

$$\frac{e^{nx} - e^{-nx}}{e^{nx} + e^{-nx}}$$

ahol n egy tanulható paraméter, ami úgy tanul, hogy kiszámolja az $\frac{\partial \mathcal{L}_{loss}}{\partial n}$ -t és eszerint a gradiens szerint növeli, vagy csökkenti az n paramétert úgy, hogy a hibát minimalizálja.

2.2 Adatok skálázása

A bemeneti változók normalizálása nem csupán a PINN architektúrák, hanem általánosságban minden neurális hálózat betanításának egyik legfontosabb alapfeltétele. A Heston-Asian modell paraméterei nagyságrendileg jelentősen eltérnek egymástól: a variancia jellemzően nagyon kicsi ($v \in [0.0001, 1]$), míg a részvényárfolyam és az átlag nagyobb tartományt fed le ($S, A \in [0, 5]$).

Ha ezeket az adatokat nyers formában táplálnánk be a hálózatba, az két súlyos, a gépi tanulásban jól ismert problémához vezetne:

- **A veszteségfüggvény torzulása:** A bemenetek nagyságrendi különbségei miatt a hibafelületen a völgyek ellipszoid alakká torzulnának. Az optimalizáló algoritmus az egyik paramétert aránytalanul jobban és gyorsabban optimalizálná, míg a másik mentén alig haladna, ami instabil és rendkívül lassú konvergenciát eredményez.

- **Az aktivációs függvények szaturációja :** Az összetett függvényben tanh aktivációs függvényeket használunk, amelyek a nulla körüli tartományban a legaktívabbak (itt a legmeredekebb a deriváltjuk). A skálázatlan, nagy bemeneti értékek a neuronok kimenetét azonnal a tanh függvény lapos, végeire tolnák. Ez azért történik meg, mert

$$\tanh'(x) = 1 - \tanh^2(x)$$

, ami $x = 0$ -tól kezdve bármelyik irányba nagyon gyorsan konvergál 0-hoz. Ez azt eredményezi, hogy sokkal lassabban tanul a háló, már nagyságrendileg közel lévő értékek esetén is.

A PINN-ek esetében ez az általános gépi tanulási szabály hatványozottan fontos. Mivel a PDE reziduális kiszámításához másodrendű deriváltakra is szükség van, az első deriváltak 0-hoz való konvergálásuk miatt megszünteti a másodrendű deriváltakat.

Ennek elkerülése érdekében egy skálázó objektumot alkalmaztam, amely minden bemeneti dimenziót szigorúan a $[-1, 1]$ zárt intervallumra transzformál az alábbi normalizáció segítségével. Egy tetszőleges x bemenetre a transzformáció képlete:

$$x_{scaled} = 2 \frac{x - x_{min}}{x_{max} - x_{min}} - 1$$

A neurális háló kizárólag ezeken a normalizált értékeken operál. Így az optimalizációs tér topológiája gömbszerűbbé, kiegyensúlyozottabbá válik, az aktivációs függvények pedig az aktív tartományukban maradnak. Megjegyzendő, hogy a PDE kiértékelésekor az automatikus differenciálás láncszabálya miatt a deriváltakat a fentebb bemutatott skálázás inverzével megfelelően korrigálni kell, hogy a PDE érvényes maradjon.

2.3 Mintavételezés: Latin Hypercube Sampling (LHS)

A fizikai tér letapogatása során egy 4 dimenziós tartományt kell lefednünk. A klasszikus, egyenletes rácsponos felosztás miatt exponenciálisan növekvő adathalmazt eredményezne, míg a tisztán egyenletes mintavétel során a pontok hajlamosak csomósodni, nagy, üresen tátongó lyukakat hagyva a 4 dimenziós térben.

Ezen probléma áthidalására a Latin Hypercube Sampling algoritmust alkalmaztam. Az LHS úgy működik, hogy a pontokat úgy helyezi el a térben, hogy minimalizálja a téren a legkisebb sűrűségű régiót

A modellemben a mintavételező algoritmus (a kódomban: Sampler) ezt kiegészíti egy a pontokat a strike price köré sűrítő transzformációval is az S és A tengelyek mentén, hiszen a deriváltak (például az opció Gammája) itt a legnagyobbak és legnehezebben tanulhatók.

2.4 Kétfázisú optimalizáció és dinamikus mintavételezés

1. Fázis: Dinamikus Adam optimalizáció

Az első szakaszban az Adam optimalizálót használjuk, amely jól kezeli a zajos, komplex felületeket. A 4 dimenziós (t, S, v, A) fázistér kezdeti felfedezése során egy komoly hardveres korlátba ütköztem: a rendelkezésre álló grafikus kártya memóriája (24 GB VRAM) nem teszi lehetővé, hogy a tér lefedéséhez szükséges több tízmillió pontot egyidejűleg a memóriában tartson, és azokon másodrendű deriváltakat számoljon.

Ezt a problémát egy dinamikus mintavételezési stratégiával hidaltam át, amely a hardveres problémát megoldja. Annak érdekében, hogy a memória ne teljen meg, de a hálózat a tér lehető legnagyobb részéből vegyen mintát, minden egyes epoch elején 25 000 teljesen új ponton generáltattam a térben.

Ez a folyamatos újra-mintavételezés garantálja, hogy bár a VRAM terhelése alacsony marad, a több ezer epoch alatt a hálózat folyamatosan új pontokkal találkozik a folytonos térből.

A betanításba beépítettem egy bemelegítő fázist is. Az első 1000 epoch során a parciális differenciálegyenlet büntetőtagjának súlyát (λ_{pde}) nullára állítottam. A PDE kikapcsolásával a hálózat először közelítőleg megtanulja a fontos peremfeltételeket.

2. Fázis: L-BFGS másodrendű finomhangolás

Sajnos az Adam optimalizáló, a globális minimum közvetlen közelében hajlamos oszcillálni. A hajszálpontos árazás, és a görögök számítása érdekében a tanítást az L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno) algoritmussal zártam.

Az L-BFGS a Hesse-mátrix inverzét közelíti, így figyelembe veszi a hibafelület görbületét is, ami rendkívül gyors és elég pontos konvergenciát biztosít a minimum pont felé. Mivel ez a módszer line search-t alkalmaz, így egy adott irányban többször is kiértékeli a függvényt, ezért a mintavételezési pontoknak szigorúan statikusnak kell lenniük. Ezért ebben a fázisban egy hatalmas, fix pontokból álló rácsot (50 000 belső pont és perempontok) szögeztem le, és ezen végeztem el az utolsó iterációkat, garantálva a PDE reziduálisok maximális kisimítását. Kicsit pontosabban, ez tulajdonképpen a Newton-Raphson módszeren alapul. Ugye az a cél, hogy megtaláljuk a függvény minimumát, vagyis amikor $\nabla f(x) = 0$. A Newton-Raphson szerint egy dimenzióban ekkor:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Vagyis több dimenzióban a Hesse-mátrix inverzével kell szorozni a gradienst minden lépésben. Az L-BFGS-ben a Hesse-mátrixot approximálják minden lépésben, ahogy egy dimenzióban is tennénk a deriváltak különbségével: $H \approx \frac{f'(x_k) - f'(x_{k-1})}{x_k - x_{k-1}}$, és a számításhoz ennek az inverzére (egydimenziós esetben a reciprokára) van szükség. Azaz a többdimenziós képlet:

$$x_{k+1} = x_k - \alpha_k B_k^{-1} \nabla f(x_k)$$

ahol a B_k a Hesse-mátrix approximációja, az α_k pedig a learning rate.

Így gyakorlatilag az első fázis megkereste elég jól a globális minimum környékét, a második fázis pedig a globális minimumot. [Kiyani et al., 2025] A paraméterek:

1. táblázat. A Heston-féle ázsiai PINN kísérletekben alkalmazott neurális architektúra és tanítási paraméterek.

Component	Value
Hidden layers	6
Neurons per layer	256 (last hidden layer: 128)
Activation function	LA AF Tanh
Optimizers	Adam, L-BFGS
Learning rate (Adam)	1×10^{-3} (with ReduceLROnPlateau)
Learning rate (L-BFGS)	1.0
Training epochs (Form learning phase)	1000
Training epochs (PDE tuning phase)	2000
Fine-tuning iterations (L-BFGS max)	10000
Interior collocation points / epoch	25000 (Adam) / 50000 (L-BFGS)
Boundary points (S_0 , $S_{\max}$) / epoch	2500 (Adam) / 5000 (L-BFGS)
Initial condition points / epoch	5000 (Adam) / 10000 (L-BFGS)

Azaz az algoritmusom az alábbi kettő egymást követve:

Algorithm 1 Dinamikus Heston-Asian PINN Tanító Algoritmus (1. Fázis: Adam)

Require: $\mathcal{T}_{max}$ (lejárat), N_{Adam} (Adam epochok száma), batch méretek, Heston paraméterek, η (tanulási ráta)

Ensure: Részben betanított neurális háló $\hat{F}_\theta(t, S, v, A)$

1: $\theta \leftarrow$ Inicializált hálózati paraméterek

1. FÁZIS: Adam Optimalizáció

2: **for** $e = 1$ **to** N_{Adam} **do**

3: Batchnyi belső pont generálása LHS-sel, majd a polinomiális torzítás: $\mathcal{P}_{in} \sim \mathcal{U}(\Omega)$

4: Batchnyi peremfeltétel, és kezdeti feltétel generálás: $\mathcal{P}_{bc}, \mathcal{P}_{ic} \sim \mathcal{U}(\partial\Omega)$

5: **if** $e \leq 1000$ **then**

6: $\lambda_{PDE} \leftarrow 0$

7: **else**

8: $\lambda_{PDE} \leftarrow 10$

9: **end if**

10: **Forward:**

11: Veszi a Batch size-nyi mintapontot, majd belerakja őket a becselőfüggvénybe.

12: **Veszteségfüggvény összeállítása:**

13: **if** $1 < S_{in} \leq 2.1$ és $A < 1.6$ **then**

14: $\lambda_{PDE} \leftarrow 20\lambda_{PDE}$

15: $\lambda_{MC} \leftarrow 20\lambda_{MC}$

16: **end if**

17: $\mathcal{L}(\theta) = \lambda_{PDE}\mathcal{L}_{PDE}(\theta) + \lambda_{ic}\mathcal{L}_{ic}(\theta) + \lambda_{bc}\mathcal{L}_{bc}(\theta) + \lambda_{mc}\mathcal{L}_{MC}(\theta)$

18: **Backpropagation:**

19: Célfüggvény gradienseinek számítása automatikus differenciálással: $g \leftarrow \nabla_\theta \mathcal{L}(\theta)$

20: **Paraméterek frissítése:**

21: $\theta \leftarrow \theta - \eta \cdot \text{Adam}(g)$

22: **end for**

Algorithm 2 Dinamikus Heston-Asian PINN Tanító Algoritmus (2. Fázis: L-BFGS)

Require: Részben betanított háló (az Adam fázisból), N_{LBFGS} (L-BFGS iterációk száma)

Ensure: Véglegesen betanított neurális háló $\hat{F}_\theta(t, S, v, A)$

2. FÁZIS: L-BFGS

1: Statikus pontok kijelölése fix perem- és kezdeti pontokkal: $\mathcal{P}_{static_lbfgs}$

2: **Definiáljuk a** $\text{Closure}(\theta)$ **függvényt az L-BFGS-hez**

3: **Forward pass** a $\mathcal{P}_{static_lbfgs}$ pontokon

4: $\mathcal{L}(\theta) \leftarrow$ Teljes veszteségfüggvény kiszámítása

5: **Backpropagation:** $g \leftarrow \nabla_\theta \mathcal{L}(\theta)$

6: **return** $\mathcal{L}(\theta)$

7: **while** Konvergencia kritérium nem teljesül és iterációk $\leq N_{L-BFGS}$ **do**

8: **Paraméterek frissítése (Newton-Raphson logika, Hesse-mátrix approximációval):**

9: **if** $1 < S_{in,MC} \leq 2.1$ és $A_{in} < 1.6$ **then**

10: $\lambda_{PDE} \leftarrow 80 \cdot \lambda_{PDE}$

11: $\lambda_{MC} \leftarrow 20 \cdot \lambda_{MC}$

12: **end if**

13: $\theta \leftarrow \text{L-BFGS_Step}(\theta, \text{Closure})$ $\triangleright$ Többszöri kiértékelés a Closure hívásával a PyTorch beépített L-BFGS optimalizálójában

14: **end while**


3. Validáció, és eredmények

Futtattam egy monte carlo szimulációt, 10000 opció árát vizsgáltam, 1000 ebből a $t = 0$. időpontban, 9000 pedig egyenletes eloszlással vett időpontokban. Az 1000 $t = 0$. egyenletes eloszlással sorsolt (v , és S szerint) időpontból, futtattam egyenként 9 szimulált utat, majd minden úthoz egyenletes eloszlással vettem egy időpontot. Ebben az időpontban megvizsgáltam, hogy mennyi az átlag, ár, variancia. Így létrehoztam 9000 új pontot, amelyek realisztikusak. 1 000 000 szimulációt futtattam 500 lépéssel az adott 10000 pontból, a Heston-modell dinamikája szerint, majd azt vizsgáltam, hogy a PINN eredmény mennyire tér el a Monte Carlo eredményétől.

2. táblázat. A PINN modell validációs statisztikái ($N = 10\,000$ tesztpont alapján)

Eltérés metrika megnevezése	Számított érték
Mean Absolute Difference	1.956000e-03
Max Absolute Difference	7.500600e-02
Mean Relative Difference	2.25%
Median Relative Difference	0.17%

Látható, 0.17 százalékos-os a medián relatív eltérés. Az is látható a táblázatból kiolvasva, hogy az átlagos relatív eltérés (2.25) sokkal magasabb a mediánnál. Ez azért van mert, a nullához közeli osztó miatt a relatív eltérés felrobban, miközben az abszolút eltérés valójában minimális (1.956e-03).




1. ábra. Monte Carlo szimulációhoz képest vett hiba értéke

3. táblázat. Hibastatisztika a pénzbeniségi kategóriák szerint

Kategória	Pontok	Átl. MC Ár	Absz. Eltérés	Rel. Eltérés (%)	Med. Rel. (%)
Deep OTM	328	0.0321	1.5000e-03	8.08%	3.93%
OTM	595	0.0769	2.4000e-03	9.97%	3.33%
ATM	514	0.1521	3.4000e-03	11.41%	1.48%
ITM	829	0.2852	2.1000e-03	2.78%	0.53%
Deep ITM	4217	1.0352	1.6000e-03	0.47%	0.14%

A táblázaton, és az alábbi ábrán látszik, hogy valóban a relatív eltérésük magas az alacsony értékű opcióknak. Ezenkívül még az is látszik, hogy az abszolút eltérésük magas az alacsony értékű opcióknak



2. ábra. Monte Carlo szimulációtól vett eltérése ("hibája") a PINN-nek különböző Monte Carlo által kiszámolt árak mellett

Az opciós árak mellett validáció gyanánt a Delta pontosságát is kiértékeltem, melynek MC becsléséhez azonos véletlen számok szerinti centrális differenciámódszert alkalmaztam.

$$\text{Delta} \approx \frac{U(S + \varepsilon; Z) - U(S - \varepsilon; Z)}{2\varepsilon}$$


Itt a jelölések a következőket jelentik:

U : Az opció becsült jelenértéke (ára) a Monte Carlo szimuláció végén.

S : Az aktuális részvényárfolyam.

ε : A kis mértékű eltolás, ami a kódban a $h = 0.01$ paraméter.


Z : Sztochasztikus mag (ugyanaz $\pm \varepsilon$ szimulációknál)



3. ábra. Kapcsolat a MC szimuláció által kiszámolt delta, és a PINN általi között


Látható, hogy a PINN által becsült opciós árak és Delták szinte tökéletesen rásimulnak az $x = y$ egyenesre, a Monte Carlo szimulációkhoz képest. Ez vizuálisan is bizonyítja, hogy a hálózat nem torzít, és sikeresen megtanulta a PDE megoldását, valamint a görögöket is.

Relatív hiba eloszlása az állapotór paramétereinek szerint




4. ábra. Monte Carlo által becsült eredménytől való eltérése a PINN-nek

Ezen az Ábrán az látszik, hogy milyen paraméterek mellett viselkedik a PINN a legrosszabbul. Látszik, hogy a kötési ár környékén volt a legnehezebb feladata, még mindig ott tanul nehezen. Továbbá a felhalmozott átlagos ár közelében, és alatta, nem tudta jól megtanulni a differenciálegyenletrendszer megoldását. Éppen ezért vezettem be azt a feltételt utólag, hogy a PINN-em $1 < S < 2.1$, és $A < 1.6$ esetén rakjanak rá extra büntetést ezekre a pontokra, hogy jobban rátanuljon.




5. ábra. Delta értéke a mögöttes termék árfolyamától függően a betanított PINN szerint

. A Delta értéke a várakozásoknak megfelelően a $[0, 1]$ intervallumon mozog. Kiemelkedő fontosságú validációs eredmény, hogy a $t = 0$ időpontban Monte Carlo szimulációval (CRN) számolt pontok (fekete kereszt markerek) szinte tökéletesen illeszkednek a PINN által analitikusan generált görbére. Ahogy a lejárat közeledik, a Delta átmenete a "OTM" és az "ITM" állapotok között egyre kevésbé meredekké válik.




6. ábra. Az opció ára a mögöttes termék árfolyamától függően a betanított PINN szerint három különböző időpontban ($t = 0.0, 0.5, 0.9$)

Látszik, hogy a részvényárfolyam növekedésével a call opció értéke monoton nő. Érdekes, hogy ahogy az idő halad, a futamidő elején ($t = 0.0$) az opció jelentős időértékkel rendelkezik, ami simábbá teszi az átmenetet a kötési ár ($K = 1.55$) környezetében.




7. ábra. Az ábra a Vegát , azaz az opció értékének varianciára való érzékenységet ábrázolja a betanított PINN szerint a mögöttes termék árfolyamától függően három különböző időpontban ($t = 0.0, 0.5, 0.9$)

Hasonlóan a Gammához, a Vega is a kötési ár környékén mutatja a legmagasabb értékeket. Ez a jelenség azzal magyarázható, hogy a volatilitás növekedése akkor adja a legnagyobb többletértéket az opciónak, amikor az éppen a lehívási határán helyezkedik el.




8. ábra. Az ábra a Vommát, a Vega variancia szerinti deriváltját mutatja be mögöttes termék árfolyamától függően a betanított PINN szerint három különböző időpontban ($t = 0.0, 0.5, 0.9$)

Ez egy rendkívül komplex, oszcilláló görbe, amely a fázistér különböző pontjain pozitív és negatív értékeket egyaránt felvesz. Ezen az ábrán mutatkozik meg igazán a PINN egyik legkomolyabb ereje. Egy ilyen másodrendű, volatilitásra vonatkozó derivált meghatározása hagyományos Monte Carlo szimulációval extrém számítási kapacitást igényelne, és a numerikus deriválás miatt erősen zajos eredményt adna. A neurális hálózat az automatikus differenciálás révén viszont ezt a bonyolult felületet is tökéletesen simán, folytonosan és extra számítási idő nélkül képes előállítani.



9. ábra. Az ábrán az opció Gammája látható a mögöttes termék árfolyamától függően a beta-nított PINN szerint három különböző időpontban ($t = 0.0, 0.5, 0.9$)

A pénzügyi elmélettel összhangban a Gamma az At-The-Money régióban, azaz pontosan a kötési árfolyam ($K = 1.55$) közelében veszi fel a maximumát, hiszen a részvényárfolyam kis elmozdulásai itt okozzák a legdrasztikusabb változást a Deltában. A lejáráthoz közeledve ($t = 0.9$ felé haladva) ez a csúcs tompul. Míg egy hagyományos európai opciónál ez a csúcs a lejáratkor végtelenhez tartana (Dirac-deltához konvergál), az ázsiai opciók átlagoláson alapuló kifizetési struktúrája ezt a hatást vizuálisan is láthatóan tompítja.



10. ábra. 2D hőterképek az opció jelenértékéről, a Gammáról és a Vegáról a mögöttes termék árfolyamának (S) és a varianciának (v) függvényében a kezdeti ($t = 0$) időpontban.

A bal oldali panelen látható, hogy az opció ára dominánsan a részvényárfolyam tengelye mentén emelkedik. A Gamma (középső panel) és a Vega (jobb oldali panel) hőterképeinél éles határvonalként rajzolódik ki a kötési ár ($K = 1.55$) környékén kialakuló magas értékű zóna.

Összegzés

Összegzés A kutatás célja az ázsiai opciók árazása és görögjeinek kiszámítása a Heston-féle sztochasztikus volatilitási modellben, a Physics-Informed Neural Network (PINN) technológia segítségével. Mivel a Heston-modell alatti ázsiai opció egy négydimenziós (idő, részvényárfolyam, variancia, átlag) parciális differenciálegyenlet megoldását igényli, ez a hagyományos numerikus eljárások (például a rácsalapú véges differencia módszer) számára komoly skálázhatósági kihívást jelent. A PINN ezzel szemben egy folytonos megoldást kínál. A matematikai levezetés és a modell alkalmazhatóságának kritikus sarokköve volt a Feller-feltétel feltevése, amely biztosította a variancia szigorúan pozitív értékét és a mértékcseré érvényességét.

A PINN teljesítményét egy 1 000 000 utat vizsgáló Monte Carlo szimulációval hasonlítottuk össze. A modell rendkívül pontosnak bizonyult: a medián relatív eltérés mindössze 0.17 százalék, az ATM opcióknál 1.48 százalék, a maximális átlagos abszolút hiba pedig elhanyagolható ($1.956e-03$). A PINN egyik legnagyobb előnye, hogy az automatikus differenciálás révén a görögök (Delta, Gamma, Vega és Vomma) folytonos függvényként, konstans idő alatt kinyerhetők a hálózathoz, teljesen kiküszöbölve a numerikus deriválásból fakadó zajt.

Konklúzió

Összességében a dolgozat bizonyítja, hogy a PINN-ek hatékony, folytonos és zajmentes alternatívát nyújtanak a komplex, útfüggő egzotikus opciók árazásában és a kockázatkezeléshez szükséges érzékenységi mutatók meghatározásában. A módszer hiányossága ugyanakkor, hogy a betanítás után "black box"-ként működik: nem transzparens, hogy a háló pontosan milyen belső folyamatok alapján jut el a megoldáshoz, ráadásul a tanítás sztochasztikus jellege miatt a folyamat nem hajszálpontosan reprodukálható.

Hivatkozások

- [Andersen and Piterbarg, 2007] Andersen, L. B. G. and Piterbarg, V. V. (2007). Moment explosions in stochastic volatility models. *Finance and Stochastics*, 11(1):29–50.
- [Cox et al., 1985] Cox, J. C., Ingersoll Jr, J. E., and Ross, S. A. (1985). A theory of the term structure of interest rates. *Econometrica: Journal of the Econometric Society*, 53(2):385–407.
- [Ekström and Tysk, 2006] Ekström, E. and Tysk, J. (2006). The black-scholes equation in stochastic volatility models. *Journal de Mathématiques Pures et Appliquées*, 86(4):276–298.
- [Hainaut and Casas, 2024] Hainaut, D. and Casas, A. (2024). Option pricing in the heston model with physics inspired neural networks. *Working Paper, UCLouvain - LIDAM*. LIDAM Discussion Paper LFIN 2024/01.
- [Kiyani et al., 2025] Kiyani, E., Shukla, K., Urbán, J. F., Darbon, J., and Karniadakis, G. E. (2025). Which optimizer works best for physics-informed neural networks and kolmogorov-arnold networks? *arXiv preprint arXiv:2501.16371*.
- [Park et al., 2025] Park, S., Moon, K.-S., and Kim, H. (2025). Asian option pricing using the physics-informed neural networks method. *Economic Computation and Economic Cybernetics Studies and Research*, 59(1):1–16.
- [PyTorch Contributors, 2024] PyTorch Contributors (2024). Softplus activation function - PyTorch documentation. Elérve: 2026.04.10.
- [Wong and Heyde, 2006] Wong, B. and Heyde, C. C. (2006). On the volatility of the Heston stochastic volatility model. *Applied Mathematical Finance*, 13(2):121–144.